Tarea 1: ciudad construida y transporte público en Santiago

OSM del 12-10-2026; GTFS V168.20261003, descargado el 13-10-2026; DPA 2023.

Iván Gallardo

`https://github.com/ivnisc/pmd`

1. Paraderos por comuna

La zona corresponde a la caja del enunciado: longitudes entre −70,75 y −70,52, y latitudes entre −33,52 y −33,36, no se restringió a una lista de comunas. El cruce punto-en-polígono con `ST_Contains` asignó los 6.812 paraderos GTFS a una única comuna, sin pérdidas ni duplicados. Las densidades dividen el conteo observado en la caja por el área comunal completa, medida en EPSG:5361.

Comuna	Paradas	Densidad	Comuna	Paradas	Densidad
Cerrillos	280	16,649	Maipú	214	1,564
Cerro Navia	163	14,748	Pedro Aguirre Cerda	192	21,994
Conchalí	317	28,979	Peñalolén	440	8,165
Estación Central	322	22,402	Providencia	270	18,693
Huechuraba	165	3,669	Pudahuel	102	0,514
Independencia	156	21,217	Quilicura	186	3,245
La Cisterna	40	3,997	Quinta Normal	286	24,229
La Florida	171	2,407	Recoleta	341	21,844
La Granja	27	2,686	Renca	239	10,092
La Reina	270	11,546	San Joaquín	246	24,756
Las Condes	376	3,796	San Miguel	192	19,941
Lo Barnechea	5	0,005	San Ramón	6	0,950
Lo Espejo	120	14,539	Santiago	624	26,921
Lo Prado	201	30,721	Vitacura	194	6,785
Macul	281	21,938	Ñuñoa	386	22,850

Densidad: paraderos observados en la caja por km^2 de comuna completa.

Santiago tiene el mayor conteo y Lo Prado la mayor densidad. Solo 13 comunas están completamente incluidas en la caja. En San Ramón se observan seis paraderos en el 2,57 % de su superficie: 0,950 paraderos/km^2 comunal frente a 36,922 sobre el área recortada. Una densidad baja en una comuna parcialmente observada no demuestra escasez en todo su territorio. Consulta y contraste recortado: `q1_paraderos_comuna.sql/.csv`.

2. Edificios a más de 500 m de un paradero

Se aplicó un anti-join con `NOT EXISTS` y `ST_DWithin` sobre el punto interior de los 118.888 edificios OSM. La proximidad mayoritaria se mantiene al cambiar de fuente, aunque existen diferencias locales.

Fuente de paraderos	Edificios alejados	Porcentaje
GTFS, todos los modos	1.347	1,133 %
GTFS, solo buses	1.349	1,135 %
OSM, `highway=bus_stop`	1.159	0,975 %

En Recoleta, el porcentaje es 1,848 % con GTFS y 0,972 % con OSM. Lo Barnechea alcanza 62,821 %, pero sobre solo 78 edificios de su recorte. Hay 318 casos alejados GTFS y 312 OSM dentro de los 500 m del borde: podrían tener paraderos exteriores excluidos. La distancia es euclidiana, sin medir acceso peatonal ni frecuencia.

El plan usa los GiST de paraderos en el lado interno de los anti-joins, filtrando cajas candidatas y confirmando la distancia, finalmente deteniéndose al encontrar un vecino. La ejecución JSON tomó 3.173,760 ms. Sin `idx_paraderos_gtfs_geom`, el control excedió 10 s, se restauró el índice mediante rollback. No se estima una aceleración a partir de ese control inconcluso. Archivos: `q2_cobertura.sql/.csv`, `q2_cobertura_plan.txt` y `q2_cobertura_sin_indice.json`.

3. Correspondencia entre GTFS y OSM a 50 m

Los anti-joins en ambos sentidos comprueban si existe al menos un vecino situado a una distancia menor o igual a 50 m; no construyen parejas únicas.

Sentido	Total	Sin vecino	Porcentaje
GTFS a OSM	6.812	452	6,635 %
OSM a GTFS	6.568	361	5,496 %
GTFS buses a OSM	6.569	380	5,785 %
OSM a GTFS buses	6.568	364	5,542 %

El contraste solo buses reduce las discrepancias GTFS, pero no las elimina. Las diferencias pueden corresponder a posición, representación, actualización u omisiones. El resultado por sí solo no permite atribuirlas a una causa ni decidir qué fuente está completa. GTFS declara lugares de embarque y OSM contiene objetos cartografiados. Consulta y resultados: `q3_correspondencia.sql/.csv`.

4. Longitud de trazados y efecto de la subdivisión

Se intersectó cada `shape_id` referido por viajes con los límites comunales. La suma es 10.079,535 km: Santiago aporta 1.339,991 km; Las Condes, 700,778 km; y Peñalolén, 662,340 km. Los sentidos y variantes podrían superponerse físicamente ya que no son kilómetros únicos de calles ni una medida de frecuencia.

Con `ST_Subdivide(...,128)` se obtienen 182 fragmentos. Las intersecciones se reúnen por comuna y shape con `ST_UnaryUnion` antes de medir, evitando duplicar segmentos en fronteras internas. Los 3.069 pares comuna-shape coinciden con el cálculo directo, y la diferencia máxima por comuna es aproximadamente $2,93 \times 10^{-8}$ m.

Variante	Mediana (ms)	Rango (ms)
Comuna completa	484,827	476,497–493,317
Comuna subdividida	371,239	365,430–410,399

Se realizó un calentamiento y cinco mediciones alternadas por variante, sin otras consultas de validación en paralelo. La reducción de la mediana fue 23,4 %, el proceso de crear fragmentos, índices y estadísticas costó otros 16,841 ms, excluidos de la comparación. Son tiempos de servidor con caché caliente, específicos de este entorno.

Ambos planes recorren los polígonos por fuera y buscan trazados mediante `idx_recorridos_geom` por dentro. Sin ese GiST se requerirían exploraciones secuenciales o un orden de join distinto que aprovechase los índices comunales, por ende no se presupone la misma estrategia. Consultas, resultados, planes y protocolo: `q4_km_comuna*`, `q4_tramos.csv` y `q4_mediciones.json`.

5. Salud más cercana a los paraderos de la ruta 514

Para esta consulta se reunieron los sentidos y variantes de la ruta 514 sin repetir `stop_id`. Para sus 239 paraderos, la farmacia, hospital, clínica o consulta médica OSM más cercana se encuentra entre 4,145

y 939,662 m, con mediana de 290,994 m. Hay 52 paraderos a más de 500 m. El máximo corresponde a PD663 y SAPU Santa Julia. Son distancias rectas a objetos registrados dentro de la caja, sin garantía de acceso peatonal, apertura o disponibilidad de atención.

El `CROSS JOIN LATERAL` aplica el filtro de categorías antes del KNN, utilizando `idx_amenidades_geom` con `<->` para cada paradero externo. Los empates se resuelven después de obtener la distancia mínima. La ejecución con GiST tomó 15,915 ms. Sin él, el control necesitó 495,982 ms y ordenó distancias tras escanear amenidades para cada parada. Estoes una comparación puntual, con rollback del cambio de índice. Archivos: `q5_salud_cercana.sql/.csv`, su plan y control sin índice.

6. Grilla hexagonal de lado 500 m

La vista materializada `mv_grilla` contiene 636 celdas recortadas a la caja. Los 118.888 edificios se asignan una sola vez por su punto interior. Los recorridos se cuentan por `route_id` distinto: los viajes o shapes de una misma ruta no multiplican su contribución.

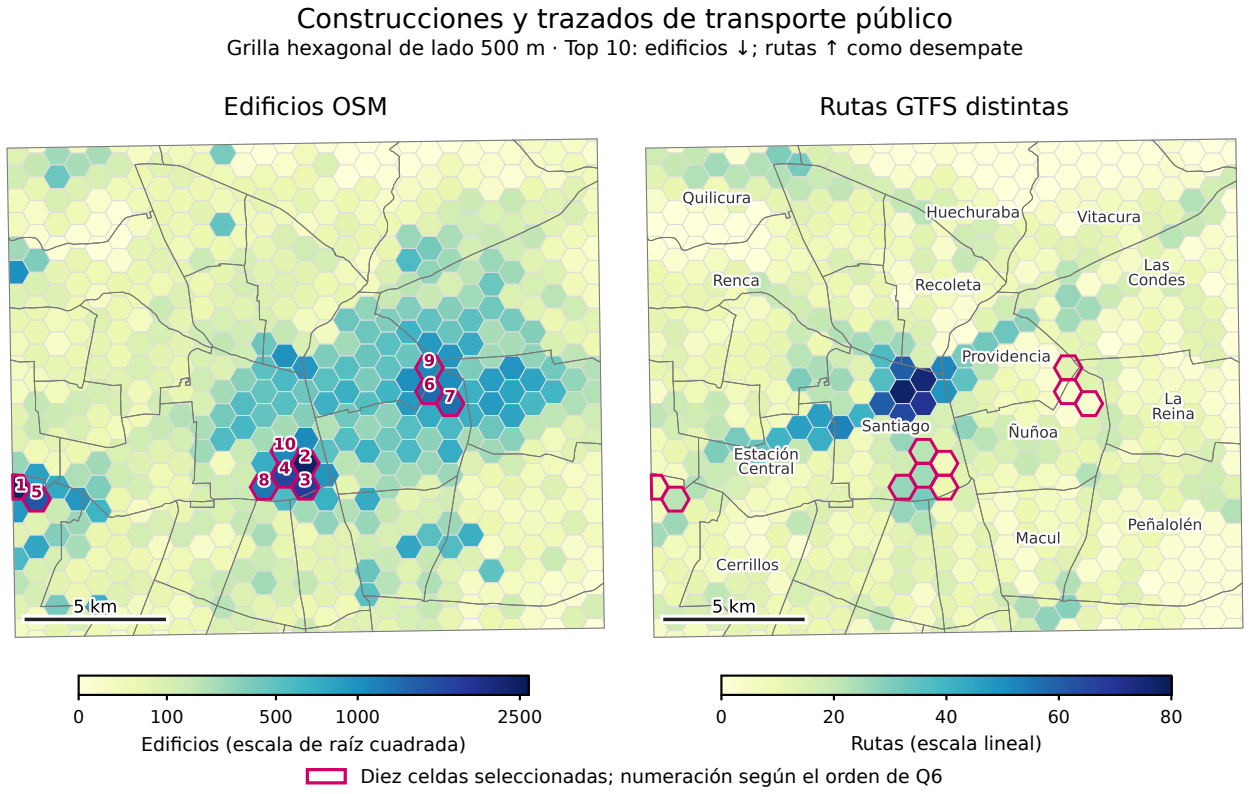


Figura 1: Mapa principal: conteos de edificios y rutas distintas en cada celda. Los contornos destacados identifican el mismo top 10 en ambos paneles. Los colores tienen escalas independientes: raíz cuadrada para edificios y lineal para rutas. Las celdas del borde tienen áreas menores.

Se interpretó «más edificios y menos recorridos» mediante edificios descendentes y rutas ascendentes como desempate, seguido de (i, j). Este orden prioriza edificios; no optimiza simultáneamente ambos criterios. No se introdujo un cociente edificios/ruta, sin embargo, las celdas con cero rutas siguen siendo elegibles.

Orden	Celda (i, j)	Edificios	Rutas distintas
1	(450, 7269)	2.532	7
2	(464, 7270)	2.450	7
3	(464, 7269)	1.870	10
4	(463, 7269)	1.741	25
5	(451, 7268)	1.551	22
6	(470, 7273)	1.344	3
7	(471, 7272)	1.321	3
8	(462, 7269)	1.244	27
9	(470, 7274)	1.098	13
10	(463, 7270)	1.091	22

En total hay 37 celdas con edificios y cero rutas, que reúnen 1.420 edificios. Esto no implica quedar a más de 500 m de un paradero: puede haber transporte en una celda adyacente. No se pondera por población ni frecuencia. Archivos: `preparar_grilla.sql`, `q6_grilla.sql/.csv`, `q6_top10.sql/.csv` y `q6_grilla.geojson`.

7. Oferta nocturna del fin de semana en sectores residenciales

¿Cómo cambia la oferta programada de buses entre noche y madrugada en sectores con construcciones residenciales OSM? Se comparan las noches viernes 16 a sábado 17 y sábado 17 a domingo 18 de octubre de 2026. La media global usa los mismos 6.569 paraderos de buses en las cuatro franjas.

Noche	Franja	Rutas con oferta	Rutas en todas las horas	Pasadas equivalentes por hora y paradero
Viernes/sábado	22:00–00:00	301	275	10,679
Viernes/sábado	00:00–06:00	279	100	2,454
Sábado/domingo	22:00–00:00	262	261	8,859
Sábado/domingo	00:00–06:00	273	85	2,299

La intensidad media baja 77,0 % y 74,0 %, respectivamente. Una ruta presente en todas las horas tiene alguna oferta en algún paradero de la caja en cada hora; no necesariamente en el mismo. Se identifican 70.291 objetos de tipos residenciales explícitos en 524 celdas; 491 contienen paraderos. De estas, 46 el sábado y 52 el domingo tienen al menos una hora de madrugada sin oferta interior.

Se respetan calendarios, excepciones y desfases desde la primera parada, incluidos servicios del día anterior. Como `exact_times=0`, se modelan pasadas equivalentes mediante segundos de solapamiento divididos por `headway_secs`; no son salidas exactas ni vehículos únicos. Los edificios no equivalen a viviendas u hogares. Consultas y resultados: `preparar_q7.sql` y `q7_resumen`, `q7_horas`, `q7_rutas` y `q7_sectores`, en SQL/CSV.

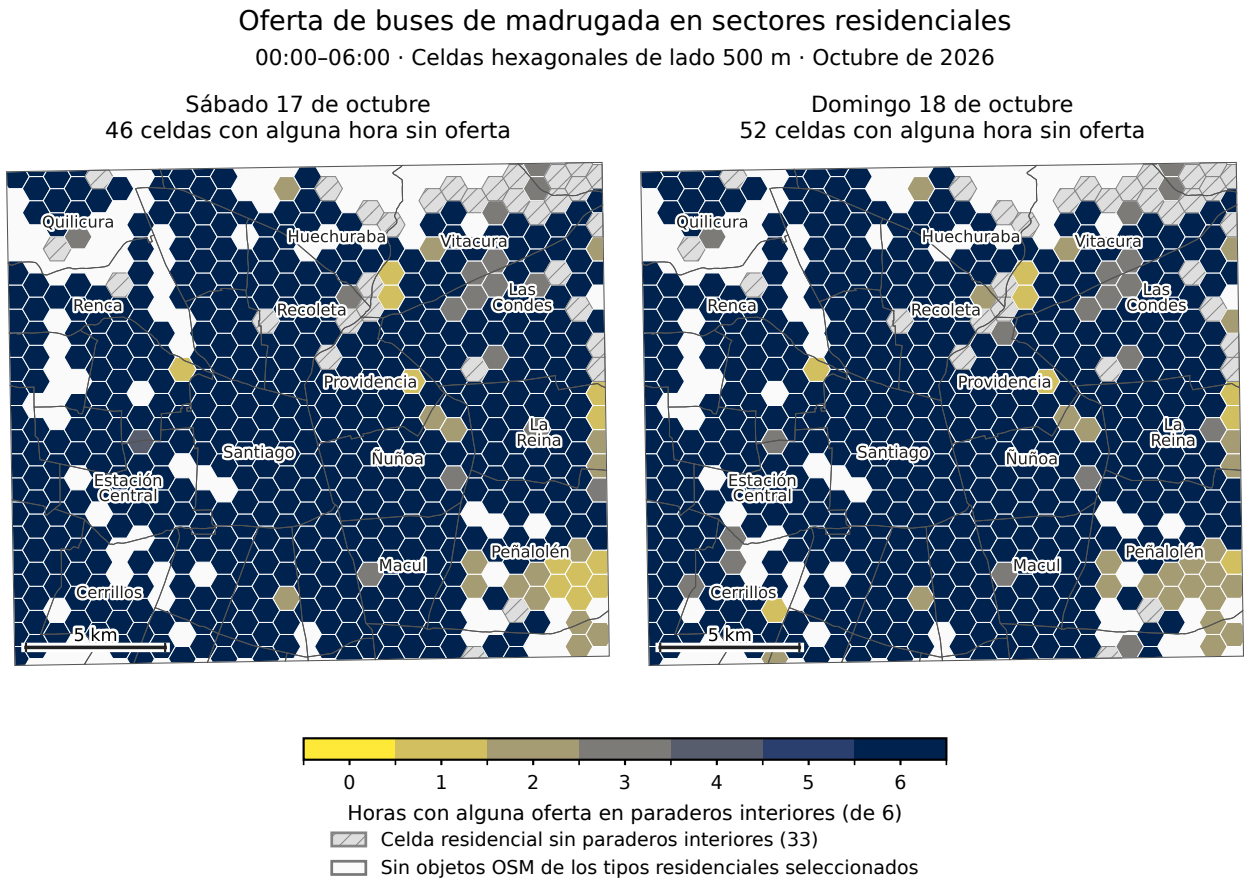


Figura 2: Intervalos horarios con alguna oferta en al menos un paradero interior de cada celda residencial, entre 00:00 y 06:00. No garantiza servicio continuo ni oferta en todos sus paraderos. Las 33 celdas tramadas pueden tener paraderos próximos fuera de sus límites. Son sectores de la grilla, sin delimitaciones barriales ni estimaciones de habitantes.

Decisiones del pipeline

Fuentes y recorte. Se fijaron los tres archivos mediante SHA-256 en `sources.json`. El PBF contiene datos hasta el 12-10-2026 a las 20:21:35 UTC; el GTFS es V168.20261003, descargado el 13-10-2026 y válido entre el 03-10 y el 31-12; la DPA corresponde a 2023. Las tres fuentes fueron descargadas el 13-10-2026, según confirmación del autor. Las URL oficiales y sus tamaños se comprobaron el 18-10-2026. La caja se aplica como delimitación efectiva, no como referencia contextual. Sus bordes se densifican cada 0,001 grados antes de reproyectarlos, evitando reemplazar paralelos por cuerdas que excluían seis edificios en la grilla.

Sistema de referencia y representación. Los puntos OSM/GTFS parten en EPSG:4326 y la DPA en EPSG:5360. Todas las geometrías de trabajo se transforman a EPSG:5361, para medir metros y superficies. Se conserva el polígono del edificio y se usa `ST_PointOnSurface` en las asignaciones y distancias: a diferencia del centroide, garantiza un punto dentro del polígono, aunque no representa su acceso. Se excluyen `building=no` y puntos interiores fuera de la caja. OSM conserva 101.204 calles, 118.888 edificios, 6.568 paraderos y 20.847 amenidades. La DPA aporta 345 comunas, 30 seleccionadas y 182 fragmentos.

Extracción y reparaciones. Filtrar el PBF durante la reconstrucción del controlador OSM de GDAL perdía vértices y generaba centenares de geometrías inválidas. Se reconstruyó primero el archivo completo en EPSG:4326 y luego se seleccionó y reproyectó. Quedaron 16 polígonos inválidos y ninguna línea inválida. Se aplicó el método del Lab 05: `ST_MakeValid`, extracción poligonal y `ST_Multi`. Los 16 quedaron válidos, sin vacíos ni pérdida de identidades. Se conservaron originales y 64 residuos lineales en `osm_reparaciones`, sin interpretarlos como superficie física nueva. Esta decisión sigue la advertencia oficial del controlador OSM.

GTFS y multiplicidad. Se cargaron ocho CSV con `COPY`, incluidos 1.098.529 registros de `stop_times`, claves, referencias y controles. Se seleccionan paradas/plataformas con `location_type` vacío o cero: 6.812 en la caja, de ellas 6.569 asociadas a buses. Los shapes se construyen con `ST_MakeLine` ordenada por secuencia: 981 completos y 708 trazados referidos por viajes que intersectan la caja. Se mantienen 859 relaciones ruta-shape y 40.473 ruta-parada. Las variantes y sentidos se conservan, Q4 cuenta shapes sin multiplicarlos por viajes, Q6 cuenta rutas distintas y Q7 usa calendarios y frecuencias según la especificación GTFS.

Índices y ejecución. Cada capa derivada tiene GiST y `ANALYZE`; las relaciones tienen claves B-tree. Q2 aprovecha los índices de paraderos, Q4 el de recorridos y Q5 el de amenidades. La auditoría `indices_uso.csv` documenta `pg_stat_user_indexes`: 19 de 51 índices propios no registraron búsquedas después de la carga, Q1–Q7 con planes y los mapas en el volumen nuevo, antes de los controles independientes. Por ejemplo, `idx_calles_geom` no registra búsquedas en esta carga de consultas: ninguna pregunta consulta las calles. Se conserva para cumplir la capa derivada indexada, y no se concluye inutilidad general. También puede recorrerse secuencialmente una tabla pequeña aunque tenga índice. Un contador cero no invalida claves que garantizan unicidad.

Reproducción y alcance. `cargar.py` prepara las tres fuentes, carga y audita un esquema temporal, y publica 25 tablas en una transacción. Elimina sus dos vistas analíticas para reconstruirlas con `analizar.py`; no mezcla resultados anteriores con nuevas fuentes. Se usan SQLAlchemy Core y pandas como en los laboratorios, conservando las consultas SQL. El README documenta el entorno, la prueba con volumen vacío y las limitaciones. Los resultados describen objetos cartográficos y oferta declarada dentro de la caja, aunque esto no prueba cobertura peatonal, demanda, población ni cumplimiento efectivo del servicio.